

KAPALI DEVRE YAPAY ZEKA PLATFORMU

YakınBoğazAI

YakınBoğazAI, “tamamen kapalı devre” çalışan, yüksek miktarda anlık sayısal veriyi işleyebilen, analiz edebilen ve hassas sonuçlar üretebilen bir yapay zeka ve veri analiz platformu olacak şekilde planlanmıştır.

YakınBoğazAI Nedir?

YakınBoğazAI, “tamamen kapalı devre” çalışan, yüksek miktarda anlık sayısal veriyi işleyebilen, analiz edebilen ve hassas sonuçlar üretebilen bir yapay zeka ve veri analiz platformu olacak şekilde planlanmıştır.

Kapalı Devre Çalışma

Sistem, dış internet bağlantısı gerektirmeden, tamamen lokal ağ üzerinde çalışarak verilerinizin maksimum güvenliğini sağlayacaktır.

Mikroservis Mimarisi

Platform, modern mikroservis mimarisi üzerine kurulacak olup, beş ana modülden oluşan entegre bir çözüm olacaktır. Her modül kendi sorumluluğunda uzmanlaşmış olup, birlikte güçlü bir veri analiz ve yapay zeka ekosistemi oluşturulması planlanmaktadır.

Ölçeklenebilirlik

Sistem, 100+ eşzamanlı kullanıcıyı destekleyebilecek şekilde tasarlanmış ve ölçeklenebilir bir yapıya sahiptir.

Doğal Dil Yorumlama

YakınBoğazAI’nın temel farkı, veri analizi sonuçlarını sadece sayısal metrikler olarak sunmakla kalmayıp, yapay zeka destekli doğal dil yorumlamaları ile kullanıcılara anlaşılır ve eyleme dönüştürülebilir içgörüler sunması amaçlanmaktadır.

YakınBoğazAI Hedef

SİSTEM HEDEFİ

Açık kaynak kodlu LLM modellerinin kapalı devre donanımlar ile, yüksek performans ve otomatize eğitim süreçleriyle büyük datanın yorumlanarak, kurumların gizlilik ve güvenlik içeriğinde Yapay Zeka sistemlerinden faydalanmasını sağlayacak yazılım ve donanım sistemi oluşturmak.

Bu sistemin farklı data akışlarına ve farklı data yorumlama ihtiyaçlarına sahip kurum/müşterilere özelleştirilebilmesini sağlayacak yapıyı kurmak.

BEKLENEN FAYDALAR

Kamu ve Özel kuruluşların büyük veri yorumlamasında, gizlilik ve veri güvenliği sağlayarak, veri entegrasyonu dinamik olarak eğitilecek yapay zeka sistemlerinden faydalanabilmelerini sağlayarak, zaman ve iş gücü tasarrufunda bulunmak, verimliliği artırarak, işe özel riskleri minimuma indirecek alt yapıyı kurmak.

Beş Ana Modül

P01 // API

API Gateway

JWT + Rate Limit

Tüm sistemin merkezi giriş noktasıdır. Kullanıcı kimlik doğrulama (JWT), yetkilendirme, rate limiting, istek yönlendirme ve güvenlik kontrolleri bu katmanda yapılır. Tüm dış istekler önce API Gateway'ye gelir, burada doğrulanır ve ilgili servise yönlendirilir.

P02 // DATA

Data Processing Service

Pandas / Polars / NumPy

Gelen verileri alır, temizler, doğrular ve analiz eder. Pandas, Polars, NumPy, SciPy ve scikit-learn ile istatistiksel analiz, zaman serisi, anomali tespiti ve tahminleme yapar. Sonuçları TimescaleDB'ye kaydeder ve Redis üzerinden cache'ler.

P03 // LLM

LLM Service

8 açık kaynak LLM • işe göre seçim

Çoklu model destekler ve işe göre model seçer. Çin ve ABD menşeli sekiz açık kaynak dil modelini birlikte çalıştırır; sorgu, rapor ve doğal dil görevini en uygun modele yönlendirir.

Llama 3.3 – Meta (ABD)
Gemma 3 – Google (ABD)
Phi-4 – Microsoft (ABD)
OLMo 2 – Allen Institute (ABD)
Qwen3 – Alibaba (Çin)
DeepSeek-V3 – DeepSeek (Çin)
GLM-4 – Zhipu (Çin)
InternLM2.5 – Shanghai AI Lab (Çin)

P04 // TRAIN

Training Service

Qdrant + LoRA / QLoRA

Model eğitimi ve RAG implementasyonu için kullanılır. Dokümanları işler, embedding'ler oluşturur ve Qdrant vector database'ine kaydeder. Fine-tuning işlemlerini yönetir ve model versiyonlaması yapar.

P05 // WEB

Web Interface

Next.js 14 + WebSocket

Next.js 14 ile geliştirilmiş modern bir frontend uygulamasıdır. Kullanıcıların sistemle etkileşim kurduğu arayüzdür. WebSocket bağlantıları ile gerçek zamanlı güncellemeler alır.

Üç Aşamalı Kurgu

STEP 1

1. Geliştirme Süreci

Geliştirilen yazılımlar, Cloud cihazlar üzerinde ilk testlerini gerçekleştirecektir. Arayüzler ve demo data eğitim modülleri ile ilk Beta ürün hazır olduğunda Demo Donanımı üzerinde kapalı devre testler yapılacaktır.

STEP 2

2. Demo Donanım

Demo Donanımı, 2-10 kullanıcıya belirli bir limit eşliğinde sistemin çalışırılığını test ettirebilecek düzeyde güce sahip bir bilgisayardır. Bu bilgisayar, LLM modellerini çalıştırılabilmesi için minimum belirtilen özelliklerde olmalıdır.

1 adet YZ işlem gücü odaklı demo eğitim ve geliştirme cihazı.

STEP 3

3. Temel Donanım

Kurumda 24 saat veri eğitimi ve 24 saat hizmet verecek bir sunucu sistemi kurulacaktır. Ham ve eğitim verisi, cihaz hatalarından etkilenmeyecek kapalı devre bir kurguda tutulur.

İki sunucu eş zamanlı çalışır. Kullanım belirli bir sınırın altına düştüğünde kaynak otomatik veri eğitimine ayrılır. 2 adet sunucu tipi YZ işlem cihazı kurulur.

Demo ve üretim konfigürasyonu

Demo eğitim cihazı

1 adet · 2–10 kullanıcı · beta ve çalışabilirlik testi

CPU	Intel Xeon 6530 · 2P 32C 2.1 GHz · 160 MB · 270 W · SGX128 (1×DSA) · 4677 XCC · 7 yıl
RAM	32 GB DDR5-5600 2Rx8 LP (16 Gb) ECC RDIMM
Disk	Samsung PM9A3 3.84 TB NVMe PCIe 4×4 M.2 · 1 DWPD SED · 5 yıl
RAID	RAID 0, 1, 10 etkinleştirme anahtarı
Ağ	Anakart üzeri 2 port 10GBase-T RJ45
GPU	NVIDIA RTX PRO 6000 Blackwell Max-Q WS · 300 W

Üretim sunucusu

2 adet · 24/7 eğitim ve hizmet · kurum içi kapalı devre

CPU	Intel Xeon 6530 · 2P 32C 2.1 GHz · 160 MB · 270 W · SGX128 (1×DSA) · 4677 XCC · 7 yıl
RAM	32 GB DDR5-5600 2Rx8 LP (16 Gb) ECC RDIMM
Disk	Samsung PM9A3 3.84 TB NVMe PCIe 4×4 M.2 · 1 DWPD SED · 5 yıl
RAID	RAID 0, 1, 10 etkinleştirme anahtarı
Ağ	Anakart üzeri 2 port 10GBase-T RJ45
GPU	NVIDIA H200 NVL · 141 GB HBM3e · PCIe 5 · 600 W · 5 yıl NVAI

Kendi verileriniz ile eğitim

Platform, kendi verilerinizle model eğitmenize olanak tanıyacak.

Projenin belirgin farklarından birisi, dinamik veri entegrasyonu ile sürekli bir eğitim otomasyonunun sağlanmasıdır.

RAG (Retrieval Augmented Generation)

PDF, DOCX, TXT gibi dokümanları yükleyerek, LLM'in bu dokümanlardaki bilgileri kullanarak daha doğru ve bağlamsal yanıtlar vermesini sağlar. Bu yöntem, model ağırlıklarını değiştirmeden, sadece doküman tabanlı zenginleştirme ile çalışır.

Fine-Tuning

LoRA (Low-Rank Adaptation) ve QLoRA yöntemleri ile mevcut LLM modellerini kendi veri setinizle eğiterek, özel davranışlar ve domain-specific bilgiler öğretebilirsiniz.

Gerçek zamanlı işleme

Kullanılacak donanıma ve kurum/işletme içi ihtiyaçlara göre platform, gerçek zamanlı veri akışlarını işleyebilir ve anında analiz sonuçları üretebilir.

Saniyede 10.000+ kayıt işleme kapasitesine sahip olan sistem, WebSocket teknolojisi ile kullanıcılara canlı güncellemeler sunar. Zaman serisi verileri için özel olarak optimize edilmiş TimescaleDB ile büyük hacimli verileri verimli bir şekilde saklar ve sorgular.

İşletme/kurum kullanıcılarının özelleşmiş ihtiyaçlarına göre periyodik veya anlık raporlamalar oluşturabilir.

● ● ● YakınBoğazAI STREAM v1.0

THROUGHPUT

10.000+

rec/sec

TRANSPORT

WebSocket

STORAGE

TimescaleDB

Dört analiz boyutu

A01

İstatistiksel Analiz

Ortalama, medyan, standart sapma gibi temel istatistiksel metriklerin yanı sıra korelasyon analizi, hipotez testleri (t-test, ANOVA, Mann-Whitney) ve dağılım analizleri yapılabilir.

A02

Zaman Serisi Analizi

Trend tespiti, mevsimsel ayrıştırma, değişim noktası belirleme ve çeşitli tahminleme yöntemleri (ARIMA, Exponential Smoothing, Prophet) ile gelecek değerleri öngörebilir.

A03

Anomali Tespiti

Z-score, IQR, Isolation Forest, DBSCAN gibi farklı yöntemlerle veri setindeki anormal değerleri tespit eder ve şiddet seviyelerine göre sınıflandırır.

A04

Makine Öğrenmesi

Regresyon, sınıflandırma ve kümeleme modelleri ile verilerden öğrenme ve tahmin yapma yeteneği sunar.

Sayısal sonuçlar, doğal dil

YakınBoğazAI'nın en öne çıkan özelliklerinden biri, analiz sonuçlarını yapay zeka ile yorumlamasıdır. Sistem, büyük dil modellerini kullanarak:

- İstatistiksel analiz sonuçlarını doğal dilde açıklar
- Anomali tespit edildiğinde olası nedenleri ve önerileri sunar
- Tahmin sonuçlarını yorumlar ve güven aralıklarını açıklar
- Kullanıcı sorularına chat bir arayüz üzerinden yanıt verir
- Türkçe ve İngilizce dil desteği ile çok dilli raporlama yapar

Kullanıcı dostu, modern bir web arayüzü

Kullanıcıların sistemle etkileşim kurduğu arayüz Next.js 14 ile geliştirilir ve WebSocket ile gerçek zamanlı güncelleme alır.

● ● ● YakınBoğazAI WEB v1.0

- Gerçek zamanlı dashboard ve görselleştirmeler
- İnteraktif grafikler ve tablolar
- Rapor oluşturma ve export (PDF, Excel, CSV)
- Dark mode desteği
- Responsive tasarım (mobil uyumlu)

Dört örnek akış

Senaryo 1

Hızlı Doküman Sorgulama

Bir kurum, iç dokümanlarını (manuel, prosedürler, teknik dokümantasyon) yükler ve çalışanlar bu dokümanlara doğal dil ile soru sorabilir. Sistem, RAG kullanarak ilgili bilgileri bulur ve yanıtlar.

Senaryo 3

Çok Dilli Raporlama

Sistem, analiz sonuçlarını hem Türkçe hem İngilizce olarak raporlayabilir. Kullanıcı, tercih ettiği dili seçer ve sistem o dilde yorumlama yapar.

Senaryo 2

Özel Domain Eğitimi

Bir finans kurumu, kendi sektörüne özel terimler, hesaplamalar ve rapor formatları öğretmek için fine-tuning yapar. Eğitilen model, finansal analiz raporlarını daha doğru yorumlar.

Senaryo 4

Anomali Tespiti ve Uyarı

Sistem, sürekli veri akışını izler ve anomali tespit ettiğinde otomatik olarak uyarı gönderir. LLM, anomaliyi açıklar ve olası nedenleri ile önerileri sunar.

İki hedef kitle

Devlet Kurumları

Sağlık, Adalet, İstatistik, Finansal, Denetim gibi konularda büyük ölçekli veri yönetimi ve analizi yapması gereken kurumlar.

Özel Sektör İşletmeler

Ölçekli üretim yapan kuruluşlar, enerji şirketleri, e-ticaret ve perakende şirketleri, finansal kuruluşlar gibi anlık üretim ve/veya piyasa verilerine göre pozisyon alan özel işletmeler.

RBAC ile beş rol

YakınBoğazAI, role-based access control (RBAC) ile farklı kullanıcı rolleri destekler.

ROL	YETKİ TANIMI
ADMIN	Tüm sistem yönetimi, kullanıcı yönetimi, sistem konfigürasyonu
ANALYST	Veri yükleme, analiz çalıştırma, rapor oluşturma, model eğitimi
VIEWER	Sadece okuma yetkisi, rapor görüntüleme
TRAINER	Model eğitimi, doküman yönetimi, RAG collection yönetimi
API USER	Sadece API erişimi, programatik kullanım

Yüksek performans kurgusu

YakınBoğazAI, yüksek performans ve ölçeklenebilirlik için optimize edilmiştir.

EŞZAMANLI

100+

Eşzamanlı Kullanıcı

Sistem, 100'den fazla kullanıcının aynı anda kullanımını destekler.

İŞLEME

<2s

İşleme Süresi

10.000 kayıtlık bir veri seti, 2 saniyeden kısa sürede analiz edilir.

LLM

<5s

LLM Yanıt Süresi

AI yorumlamaları, 5 saniyeden kısa sürede üretilir.

SCALE

∞

Horizontal Scaling

Docker Compose ile servis replikasyonu yapılabilir.

CACHE

Redis

Caching

Sık kullanılan sonuçlar cache'lenir, yanıt süreleri optimize edilir.

Kapsamlı materyal

Sistem, kapsamlı dokümantasyon ve eğitim materyalleri ile birlikte gelir.

API Dokümantasyonu

Swagger UI üzerinden interaktif API dokümantasyonu.

Kullanıcı Kılavuzu

Web arayüzü kullanımı, adım adım rehberler.

Mimari Dokümantasyon

Sistem mimarisi, teknoloji stack, veri akışları.

Kurulum Kılavuzu

Detaylı kurulum ve yapılandırma adımları.

Örnek Senaryolar

Yaygın kullanım senaryoları ve örnekler.